Sistema de detección y respuesta temprana para redes IIoT en el borde (Edge) usando modelos livianos (TinyML), aprendizaje federado y cifrado ligero, desplegado en Raspberry Pi 5

Santiago Alejandro Jaimes Puerto
Nicolas Casas Ibarra

Universidad de Los Andes
Departamento de Ingeniería de sistemas y computación
Bogotá, Colombia
2026

Sistema de detección y respuesta temprana para redes IIoT en el borde (Edge) usando modelos livianos (TinyML), aprendizaje federado y cifrado ligero, desplegado en Raspberry Pi 5.

Santiago Alejandro Jaimes Puerto
Nicolas Casas Ibarra

University de Los Andes
Presentado en cumplimiento parcial de los requisitos para el grado de:
System and Computer engineer

Director:
Prof. Carlos Andrés Lozano Garzón, PhD
Trabajo de grado defendido en:
Mayo 24, 2026 - 12:00 pm

Universidad de Los Andes
Departamento de Ingeniería de Sistemas y Computación
Bogotá, Colombia
2026

Agradecimientos

Quiero expresar mi más sincera gratitud a todas las personas que hicieron posible este logro.

A mi familia, quienes han sido mi ancla y mi inspiración en cada paso de este camino. Su amor incondicional y apoyo constante me han dado la fortaleza para superar cualquier desafío.

Al profesor Paulo de Oliveria, mi asesor, quien no solo compartió generosamente su conocimiento y experiencia, sino que también fue un guía incansable durante este proyecto. Su paciencia, dedicación y constante disposición para resolver dudas fueron esenciales para enfrentar los retos que surgieron. Sus valiosos comentarios y orientaciones me permitieron aprender y crecer, tanto a nivel académico como personal. Este proyecto no habría sido lo mismo sin su acompañamiento e inspiración.

A la Universidad de los Andes, mi alma máter, por ser un espacio de excelencia académica que me permitió desarrollar mis habilidades y consolidar mi formación profesional. A sus profesores, administrativos y recursos de investigación, les agradezco por fomentar un ambiente de aprendizaje integral, colaboración y crecimiento personal. Haber formado parte de esta comunidad académica ha sido un privilegio invaluable que marcará para siempre mi trayectoria.

Y, con un cariño especial, a mis amigos. Gracias por convertir este recorrido en una aventura inolvidable. A Sebastián Moya, por su apoyo clave y su disposición.

A todos ustedes, mi eterno agradecimiento. Este logro también es suyo.

Resumen

Este documento presenta el desarrollo y la validación de modelos de inteligencia artificial basados en **aprendizaje supervisado** para la identificación de parámetros de fabricación en nanocompuestos de nanotubos de carbono y poliimida (CNT/PI). El objetivo principal es establecer un vínculo cuantitativo entre la microestructura del material y sus condiciones de síntesis (voltaje y frecuencia de alineación), utilizando imágenes de Microscopía de Fuerza Electrostática de segundo armónico ($2\omega_e$-EFM) como fuente de información. Se aborda el desafío de la escasez de datos experimentales mediante la implementación de un *pipeline* robusto de preprocesamiento y estrategias de aumento de datos, comparando el desempeño de arquitecturas basadas en convoluciones (CNN) frente a modelos basados en *Transformers*.

En la primera fase, se optimiza la calidad de las micrografías mediante algoritmos de corrección de fondo, filtrado de ruido y eliminación de artefactos de barrido (*destriping*), garantizando la homogeneidad de los datos de entrada. Posteriormente, se entrena y valida un conjunto de arquitecturas de visión por computadora (ResNet18, MobileNetV3, ViT y Swin Transformer) utilizando validación cruzada (K-Fold), con el fin de clasificar las muestras según sus parámetros de fabricación y evaluar la capacidad de generalización de cada modelo en un régimen de datos limitados.

Como parte de la evaluación, se evidencia que la frecuencia de fabricación deja una huella visual más distintiva que el voltaje, permitiendo una clasificación más precisa. Un hallazgo crítico es la superioridad de las CNNs sobre los Transformers en este escenario: mientras que los modelos ViT sufrieron de sobreajuste severo debido a la escasez de datos, las arquitecturas ligeras como **MobileNetV3** demostraron una mayor estabilidad y capacidad predictiva, logrando los mejores resultados en términos de *F1-Score* y AUC.

En síntesis, la investigación demuestra la viabilidad de utilizar el aprendizaje supervisado para realizar ingeniería inversa del proceso de fabricación de nanocompuestos de manera no destructiva. Se concluye que, para aplicaciones de microscopía con datasets acotados, las arquitecturas convolucionales eficientes ofrecen un balance óptimo entre complejidad y precisión, abriendo la puerta a futuros sistemas de control de calidad automatizados en la manufactura de nanomateriales avanzados.

Keywords: Nanocompuestos CNT/PI, Aprendizaje Supervisado, Microscopía EFM-$2\omega_e$, Visión por Computadora, MobileNetV3, ResNet18, Vision Transformers, Clasificación de Imágenes, Escasez de Datos.

Tabla de Contenido

List of Figures x

List of Tables xi

1. Introducción 1
- 1.1. Contexto . . . 1
- 1.2. Problemática . . . 2
- 1.3. Justificación . . . 3
- 1.4. Objetivos . . . 4
  - 1.4.1. Objetivo General . . . 4
  - 1.4.2. Objetivos Específicos . . . 4
  - 1.4.3. Pregunta de investigación . . . 4

2. Marco Teórico 5
- 2.1. Marco Conceptual . . . 5
  - 2.1.1. Internet de las Cosas (IoT) y Redes IoT/IIoT . . . 5
  - 2.1.2. Sistemas de Detección de Intrusiones (IDS/NIDS) en IoT . . . 5
  - 2.1.3. Captura de tráfico y representación: PCAP, flujos y logs . . . 6
  - 2.1.4. Computación en el borde y Raspberry Pi 5 como nodo de seguridad . 6
  - 2.1.5. TinyML para detección en dispositivos restringidos . . . 7
  - 2.1.6. Aprendizaje federado (Federated Learning) en ciberseguridad . . . 7
  - 2.1.7. Cifrado ligero y protección de artefactos en FL . . . 7
  - 2.1.8. NLP aplicado a logs de red y analítica operacional . . . 8
  - 2.1.9. Transformers para secuencias y detección basada en representación . 8
- 2.2. Estado del Arte . . . 9

3. Metodología 13

4. Resultados 14

5. Conclusiones y Trabajos Futuros 15

Bibliografía 15

A. Anexos **19**
A.1. Anexo A: Resultados Suplementarios 19

Lista of Figuras

Lista de Tablas

2-1. Resumen del Estado del Arte en IDS para IoT/IIoT con Edge/TinyML, FL, criptografía ligera y NLP. 11

1. Introducción

1.1. Contexto

La adopción acelerada de soluciones *Internet of Things* (IoT) y *Industrial IoT* (IIoT) en manufactura, energía, logística, salud y ciudades inteligentes ha incrementado de forma sustancial la superficie de ataque de las redes, al incorporar dispositivos heterogéneos, protocolos diversos y nodos con capacidades limitadas de cómputo y seguridad. En la práctica, esta expansión convive con retos operacionales frecuentes: configuraciones débiles, ciclos de actualización irregulares y conectividad intermitente, lo cual incrementa la probabilidad de intrusiones y tráfico malicioso persistente. En este escenario, la ciberseguridad debe entenderse como un conjunto de capacidades de gestión del riesgo y de operación continua, alineadas con marcos como el *NIST Cybersecurity Framework* (CSF), donde la detección y el monitoreo oportuno son funciones esenciales para reducir impacto y tiempo de respuesta [1].

Una medida clave para fortalecer la función de detección en redes IoT/IIoT es el uso de *Intrusion Detection Systems* (IDS) orientados a tráfico, capaces de identificar patrones de ataques conocidos y anomalías emergentes. Sin embargo, el despliegue de IDS en estos entornos no se limita a maximizar métricas de clasificación; también exige viabilidad técnica en *edge gateways* y dispositivos restringidos, donde el consumo de recursos, la latencia de inferencia y la estabilidad bajo carga resultan determinantes [2]. En particular, el uso de plataformas de borde como Raspberry Pi habilita procesar tráfico cerca de la fuente, reduciendo latencias y dependencia de conectividad, pero obliga a seleccionar modelos y *pipelines* compatibles con restricciones reales. En este punto, enfoques de *TinyML* y ML eficiente aportan herramientas para desplegar modelos livianos con tamaños reducidos y tiempos de inferencia acotados [3].

Paralelamente, las necesidades de privacidad y las limitaciones para centralizar datos crudos (p. ej., capturas PCAP) hacen pertinente considerar esquemas de entrenamiento distribuido como el aprendizaje federado (FL), donde se comparten actualizaciones de modelos en lugar de datos [4]. Además, la riqueza semántica y secuencial de los logs derivados del tráfico (por ejemplo, eventos tipo Zeek) abre la posibilidad de incorporar NLP para capturar patrones temporales y contextuales que pueden perderse en representaciones agregadas [5, 6]. En conjunto, estos elementos motivan un IDS integral para IoT/IIoT que sea (i) eficiente en el borde, (ii) actualizable de manera distribuida y (iii) robusto al analizar tanto características

numéricas como secuencias de eventos.

1.2. Problemática

A pesar de los avances en detección basada en ML/DL, persisten brechas relevantes al intentar llevar un IDS desde el laboratorio hacia un escenario IoT/IIoT operativo. En primer lugar, muchas aproximaciones asumen procesamiento centralizado: capturar tráfico, transferirlo a servidores con recursos amplios y entrenar o inferir en la nube. En redes IIoT, esta suposición puede ser inviable por restricciones de ancho de banda, políticas de privacidad o latencias operacionales, especialmente cuando se consideran capturas PCAP o grandes volúmenes de telemetría [2].

En segundo lugar, incluso cuando se decide procesar en el borde, emerge un desafío de **viabilidad computacional**. Un IDS en un *gateway* debe sostener operación continua con inferencias frecuentes, sin degradar el funcionamiento del dispositivo ni introducir cuellos de botella. Esto obliga a elegir modelos livianos, estrategias de selección de características y, en algunos casos, compresión o cuantización [3].

En tercer lugar, el comportamiento del tráfico en IoT/IIoT es altamente heterogéneo y puede variar por sitio, tiempo y tipo de dispositivo. Esto produce distribuciones de datos *non-IID* y deriva en *concept drift*, reduciendo la generalización de modelos entrenados de forma estática. El aprendizaje federado se plantea como una alternativa para actualización distribuida, pero introduce retos operacionales: comunicación costosa, participación parcial, conectividad eventual y heterogeneidad de hardware [4, 7].

Finalmente, aunque el tráfico capturado (PCAP) ofrece detalle a nivel de paquete, transformar dicho tráfico en representaciones útiles para ML no es trivial. Las características de flujo (*flow features*) facilitan modelos compactos, pero pueden perder contexto temporal y secuencial importante. En contraste, los logs semiestructurados derivados del tráfico permiten analizar secuencias de eventos, abriendo la puerta al uso de NLP y Transformers para detección de anomalías, pero estos enfoques suelen ser más costosos computacionalmente y requieren diseño cuidadoso para ser compatibles con edge [6, 8].

A estas brechas se suma un requisito transversal: **proteger los artefactos y comunicaciones** involucrados en captura, almacenamiento y actualización de modelos. En escenarios con aprendizaje distribuido, las actualizaciones intercambiadas y los modelos almacenados localmente se convierten en activos críticos, lo que justifica considerar mecanismos de protección de bajo costo computacional, como criptografía ligera estandarizada para dispositivos restringidos [9].

1.3. Justificación

Esta tesis se justifica por la necesidad de proponer y evaluar una solución integral y factible para detección de intrusiones en IoT/IIoT, que no se limite a reportar métricas de clasificación, sino que valide su ejecución en un nodo *edge* realista (Raspberry Pi 5) bajo restricciones de CPU/RAM y latencia. La literatura reciente respalda que, para IDS *on-device*, el costo operacional (latencia, energía y memoria) es tan determinante como la precisión, por lo que una evaluación completa debe incluir métricas de despliegue [2]. En este sentido, *TinyML* y ML eficiente ofrecen herramientas para construir modelos livianos y sostenibles en hardware limitado [3].

Adicionalmente, se propone incorporar aprendizaje federado como estrategia de actualización colaborativa, reduciendo la necesidad de centralizar datos crudos y atendiendo restricciones de privacidad y conectividad. Dado que FL en IoT enfrenta retos de heterogeneidad y datos *non-IID*, esta tesis lo evalúa en un escenario controlado (simulación con particiones) midiendo su costo de comunicación y desempeño frente a entrenamiento centralizado [4, 10].

Como aporte complementario, se integra NLP sobre logs derivados del tráfico (por ejemplo, secuencias tipo Zeek), para capturar patrones temporales y contextuales asociados a ataques que no necesariamente emergen en agregaciones numéricas. Los enfoques basados en Transformers para logs han mostrado potencial para detección de anomalías, motivando su exploración en combinación con un pipeline de borde [6, 8, 5].

Finalmente, la tesis incorpora protección de bajo costo computacional para artefactos y mensajes de actualización (cuando aplique), apoyándose en lineamientos y estándares de criptografía ligera para dispositivos restringidos, con el fin de aumentar la aplicabilidad de la solución en escenarios reales [9].

El documento está estructurado de la siguiente manera: **1)** Introducción, **2)** Marco Teórico el cual a su vez está dividido en **2.1)** Marco Conceptual y **2.2)** Estado del Arte, **3)** Metodología, **4)** Resultados, **5)** Conclusiones y Trabajos Futuros, **??)** **??**. Adicionalmente, si desea consultar los scripts de las rutinas en Python implementadas en este trabajo, así como el modelo del sistema IEEE de 8 barras utilizado en *DigSilent PowerFactory*, puede acceder a ellos a través del siguiente enlace: Repositorio del proyecto.

1.4. Objetivos

1.4.1. Objetivo General

Diseñar e implementar un prototipo de detección de intrusiones para redes IoT/IIoT en un nodo *edge* (Raspberry Pi 5), combinando modelos livianos, análisis de logs con NLP y una evaluación de aprendizaje federado, incorporando mecanismos de protección de comunicaciones de bajo costo computacional.

1.4.2. Objetivos Específicos

1. Construir el *pipeline* de datos a partir de capturas/representaciones del tráfico (PCAP y/o derivados), incluyendo preprocesamiento, extracción de características de flujo y generación de logs/eventos para análisis secuencial, definiendo esquemas de etiquetas (binario y/o multiclase) sobre uno o más datasets públicos de IoT/IIoT.

2. Entrenar y comparar modelos livianos para detección/clasificación de ataques, aplicando estrategias de eficiencia (selección de características, compresión y/o cuantización cuando aplique) para asegurar viabilidad en Raspberry Pi 5 [3].

3. Diseñar un componente basado en NLP para análisis de logs derivados del tráfico, evaluando representaciones y modelos secuenciales (p. ej., enfoques tipo Transformer/-BERT para anomalías o clasificación) y estudiando su complementariedad con modelos basados en *flow features* [6, 8, 5].

4. Desplegar el IDS en Raspberry Pi 5 y medir desempeño en ambiente *edge* (latencia de inferencia, consumo CPU/RAM, estabilidad bajo carga y calidad de detección), comparando configuraciones con y sin componente NLP.

5. Implementar y evaluar un esquema federado (al menos en simulación con particiones y/o múltiples nodos) y cuantificar su impacto frente a entrenamiento centralizado (calidad, rondas, costo de comunicación), incorporando protección básica de mensajes/artefactos mediante criptografía ligera cuando corresponda [4, 9].

1.4.3. Pregunta de investigación

¿Qué tan efectivo y eficiente es un IDS liviano desplegado en Raspberry Pi 5 para redes IoT/IIoT al combinar modelos de clasificación compactos con análisis de logs mediante NLP, y cuánto mejora su aplicabilidad cuando la actualización del modelo se realiza de forma federada y sus comunicaciones/artefactos se protegen con criptografía ligera?

2. Marco Teórico

2.1. Marco Conceptual

En esta sección se definen los conceptos teóricos que sustentan el diseño e implementación de un sistema de detección de intrusiones (IDS) en el borde, ejecutable en una *Raspberry Pi 5*, que integra *TinyML*, *aprendizaje federado* (FL), *cifrado ligero* y *NLP* aplicado a logs de red, conforme al enfoque de ciberseguridad y gobernanza descrito en la propuesta y en marcos de referencia vigentes [11].

2.1.1. Internet de las Cosas (IoT) y Redes IoT/IIoT

El **Internet de las Cosas** (IoT) se refiere a ecosistemas de dispositivos conectados (sensores, actuadores, cámaras, gateways y equipos embebidos) que generan, transmiten y consumen datos a través de redes heterogéneas. En contextos industriales (IIoT), estos dispositivos suelen operar en ambientes con requisitos de disponibilidad, continuidad y seguridad más estrictos, al soportar procesos críticos y telemetría operativa. En consecuencia, las redes IoT/IIoT presentan una superficie de ataque amplia, con una alta diversidad de protocolos, patrones de tráfico y limitaciones de recursos, lo que incrementa la complejidad de la detección oportuna de amenazas.
Desde la perspectiva de gestión de ciberseguridad, estas redes deben abordarse como parte de un sistema socio-técnico con activos, riesgos y controles. En ese sentido, marcos como el *NIST Cybersecurity Framework (CSF) 2.0* organizan la gestión del riesgo y la operación de seguridad mediante funciones y categorías que facilitan la alineación entre objetivos técnicos (p. ej., detección y respuesta) y gobierno/gestión (p. ej., priorización y métricas) [11]. Esta estructura es relevante para justificar, evaluar y reportar el valor del IDS propuesto como un control técnico dentro de una estrategia de seguridad más amplia.

2.1.2. Sistemas de Detección de Intrusiones (IDS/NIDS) en IoT

Un **Sistema de Detección de Intrusiones** (IDS) es un mecanismo de monitoreo y análisis cuyo propósito es identificar actividad maliciosa o anómala en un entorno computacional. Cuando su foco principal es el análisis del tráfico y los eventos de red, se suele denominar **IDS de red** (NIDS). En IoT, los NIDS se enfrentan a retos adicionales: tráfico ruidoso,

dispositivos con comportamientos variables, cambios de topología, y restricciones de cómputo y energía para instrumentar monitoreo cercano a la fuente.

La evidencia reciente muestra enfoques que buscan ejecutar detección en el borde para reducir latencia, evitar el envío masivo de datos y mejorar la reacción ante incidentes. En particular, se han propuesto mecanismos de detección basados en modelos ligeros (p. ej., *TinyML*) para operar con memoria acotada e inferencia rápida [12, 13, 14]. En este marco, el diseño de un IDS debe considerar tanto métricas de precisión (p. ej., *precision*, *recall*, *F1*) como métricas operativas (latencia, uso de CPU/memoria, energía), especialmente en dispositivos restringidos [14].

2.1.3. Captura de tráfico y representación: PCAP, flujos y logs

Una **captura de tráfico** en formato **PCAP** almacena paquetes de red (cabeceras y, dependiendo del punto de captura, potencialmente carga útil), permitiendo reconstrucción y análisis detallado. Sin embargo, para tareas de detección automatizada es común transformar el tráfico a representaciones más compactas y estructuradas, como **flujos** (agrupaciones de paquetes por 5-tupla y ventanas temporales) y **logs** de eventos de red.

Entre las alternativas de representación, los **logs de Zeek** son ampliamente usados porque convierten observaciones de red en registros tabulares/semiestructurados (p. ej., conexiones, DNS, HTTP), con campos que capturan contexto operacional (origen/destino, puertos, duración, bytes, estados) y facilitan analítica posterior. Esto resulta especialmente útil para integrar dos rutas del sistema: (i) clasificación basada en características numéricas de flujos y (ii) analítica basada en texto/plantillas para *NLP* sobre logs, como se plantea en la propuesta [15, 16, 17].

2.1.4. Computación en el borde y Raspberry Pi 5 como nodo de seguridad

La **computación en el borde** (*edge computing*) desplaza procesamiento y analítica hacia nodos cercanos a la fuente de datos, con el objetivo de disminuir latencia, reducir dependencia de conectividad y limitar el volumen de información enviado a la nube. En seguridad, esto habilita despliegues donde el IDS detecta y actúa localmente, y además coordina aprendizaje y actualización de modelos de manera distribuida.

En este proyecto, la **Raspberry Pi 5** se considera un nodo factible para el borde por combinar capacidad de cómputo de propósito general y conectividad, permitiendo captura/preprocesamiento de tráfico, inferencia con modelos compactos y coordinación de rondas federadas, de acuerdo con la arquitectura planteada en la propuesta. Adicionalmente, su disponibilidad en variantes de memoria (incluida 8 GB) facilita experimentación con componentes ligeros de *NLP* y evaluación de consumo de recursos en condiciones realistas [18].

2.1.5. TinyML para detección en dispositivos restringidos

TinyML es un enfoque que busca ejecutar modelos de *machine learning* en hardware con recursos limitados (memoria, CPU, energía), mediante modelos compactos, optimizaciones (p. ej., cuantización) y diseños orientados a inferencia eficiente. En seguridad IoT, TinyML se ha propuesto para detectar anomalías o ataques cerca del origen, favoreciendo respuesta rápida y minimizando dependencia de infraestructura central.
Trabajos recientes muestran diseños de IDS basados en TinyML y resaltan un conjunto de tensiones típicas: precisión vs. tamaño del modelo, latencia vs. complejidad, y consumo energético vs. frecuencia de inferencia [12, 13, 14]. En consecuencia, el marco conceptual del proyecto requiere considerar TinyML no solo como "modelos pequeños", sino como un *conjunto de decisiones de diseño* (arquitecturas ligeras, selección de variables/atributos, compresión) alineadas con restricciones observables en la Raspberry Pi y/o nodos IoT.

2.1.6. Aprendizaje federado (Federated Learning) en ciberseguridad

El **aprendizaje federado** (FL) es un paradigma de entrenamiento distribuido donde múltiples nodos entrenan localmente un modelo y comparten únicamente actualizaciones (p. ej., gradientes o pesos) con un agregador, evitando centralizar los datos crudos. En escenarios IoT, FL se ha estudiado como mecanismo para mitigar riesgos de privacidad y para aprovechar datos distribuidos (por ejemplo, redes segmentadas o entidades con restricciones de compartición).
La literatura reciente enfatiza que FL en IDS enfrenta desafíos específicos: datos *no IID* (distribuciones distintas por nodo), heterogeneidad de hardware y conectividad, y costos de comunicación durante las rondas de agregación [19, 20]. Por ello, el marco conceptual del proyecto asume que la "calidad" del enfoque federado no depende únicamente del algoritmo de agregación, sino también del diseño experimental (particiones, balance, escenarios) y de cómo se mide estabilidad/eficiencia en presencia de restricciones reales.

2.1.7. Cifrado ligero y protección de artefactos en FL

El **cifrado ligero** (*lightweight cryptography*) agrupa técnicas criptográficas diseñadas para dispositivos con limitaciones de memoria, energía y capacidad de cómputo, manteniendo propiedades de confidencialidad e integridad con costos controlados. Su relevancia en este proyecto está asociada a proteger **artefactos de seguridad** intercambiados o almacenados por el sistema (por ejemplo, parámetros del modelo en FL, mensajes de control, y salidas/alertas persistentes), especialmente cuando los nodos operan en redes potencialmente expuestas.
NIST estandarizó primitivas para contextos restringidos, incluyendo esquemas basados en Ascon para cifrado autenticado, *hash* y funciones extensibles, lo que proporciona una referencia técnica sólida para seleccionar mecanismos compatibles con el escenario IoT [21].

Complementariamente, revisiones recientes sintetizan criterios de selección y *trade-offs* (seguridad, implementación, costo computacional) para despliegues IoT, lo cual soporta la decisión de "cifrar lo que se comparte" incluso si el entrenamiento evita mover datos crudos: en FL, las actualizaciones siguen siendo un activo sensible y su manipulación o filtración puede afectar privacidad, integridad del modelo y confianza operativa [22].

2.1.8. NLP aplicado a logs de red y analítica operacional

El **procesamiento de lenguaje natural** (NLP) se centra en representar y modelar secuencias simbólicas (texto) para tareas como clasificación, extracción de entidades, resumen o explicación. En ciberseguridad, los **logs** (incluidos logs de red y de sistemas) pueden reinterpretarse como secuencias "textuales" donde cada evento aporta tokens/campos que describen comportamiento, habilitando modelos que aprenden patrones temporales y contextuales.

En la propuesta, el componente de NLP se justifica por su valor operativo: (i) transformar logs estructurados en representaciones aprendibles, (ii) apoyar explicabilidad (p. ej., "por qué se disparó una alerta"), y (iii) priorizar o resumir eventos para facilitar la respuesta. Evidencia reciente reporta el uso de Transformers para aprendizaje de patrones en logs (incluyendo enfoques federados) [23, 24] y evaluaciones comparativas de modelos tipo LLM como clasificadores sobre datos derivados de flujos/logs (incluyendo Zeek) frente a baselines de ML/DL [17].

2.1.9. Transformers para secuencias y detección basada en representación

Los **Transformers** son arquitecturas basadas en mecanismos de atención que permiten modelar dependencias en secuencias sin requerir recurrencia explícita. En el contexto de seguridad, su aporte se observa en la capacidad de capturar patrones de largo alcance en series de eventos (logs) o en secuencias construidas a partir de flujos/red, especialmente cuando el comportamiento anómalo depende de combinaciones distribuidas en el tiempo.

Dentro de esta línea, **LogBERT** plantea la detección de anomalías en logs mediante representaciones inspiradas en BERT, evidenciando que el enfoque puede aprender estructura contextual útil para distinguir comportamiento normal de anómalo [24]. Asimismo, se han propuesto Transformers federados e interpretables para aprendizaje de logs en escenarios distribuidos, lo que conecta directamente con la integración FL+NLP planteada en el proyecto [23]. En conjunto, estas referencias soportan la hipótesis de que una combinación híbrida (TinyML para detección "en línea" y NLP ligero para interpretación/explicación) puede ser factible si se controla el costo computacional y se evalúan *trade-offs* frente a alternativas clásicas [17, 14].

2.2. Estado del Arte

La creciente adopción de dispositivos IoT/IIoT en hogares, ciudades e industrias ha ampliado de forma significativa la superficie de ataque, debido a la heterogeneidad de protocolos, la gestión desigual de credenciales/actualizaciones y la exposición continua de servicios en red. En este contexto, los *Intrusion Detection Systems* (IDS) han cobrado relevancia como controles de detección y monitoreo, especialmente cuando se alinean con marcos de gestión del riesgo y capacidades de ciberseguridad (p. ej., identificación, protección, detección, respuesta y recuperación) [1]. Sin embargo, una tendencia clara en la literatura reciente es que la efectividad de un IDS no depende únicamente del algoritmo de clasificación, sino del *pipeline* completo: captura y representación de tráfico, calidad/realismo del dataset, viabilidad de despliegue en el borde y mecanismos de actualización del modelo bajo restricciones operativas.

Un primer eje del estado del arte se centra en la disponibilidad de **datasets** públicos para evaluación reproducible de IDS. UNSW-NB15 y Bot-IoT se mantienen como referentes por su uso extendido como *baseline* de intrusión y por incluir escenarios asociados a ataques en red e IoT, respectivamente [25, 26]. TON_IoT incorpora un enfoque más multimodal al incluir telemetría, logs y tráfico de red, lo cual habilita experimentos que integran señales heterogéneas (p. ej., flujos numéricos y registros semiestructurados) [27, 28]. En una línea complementaria, IoT-23 destaca por ofrecer escenarios etiquetados basados en capturas tipo PCAP, lo que facilita enfoques que parten de Wireshark/PCAP y luego derivan logs o flujos para entrenamiento [29]. Por su parte, Edge-IIoTset fue propuesto explícitamente para evaluar aprendizaje centralizado y federado en IoT/IIoT, aportando realismo para experimentos FL desde el diseño del dataset [30]. Finalmente, CICIoT2023 amplía la escala y variedad de ataques para condiciones más cercanas a operación real, consolidándose como *benchmark* reciente de alto valor para comparar modelos [31].

Un segundo eje corresponde al **despliegue en el borde** y el uso de modelos eficientes (**TinyML**) para detección cercana a la fuente. Las revisiones recientes sobre TinyML enfatizan que la contribución clave no es únicamente "hacer el modelo pequeño", sino diseñar un conjunto coherente de decisiones de ingeniería: selección de variables, reducción de dimensionalidad, compresión/cuantización y un *pipeline* de inferencia estable bajo carga [3]. En particular, Tekin et al. evidencian que, en IDS *on-device*, el consumo energético y la latencia varían sustancialmente según el modelo y la representación de entrada, por lo que la evaluación debe reportar métricas de despliegue (energía, tiempo de inferencia, huella de memoria) junto con métricas de clasificación [2]. Esto es especialmente relevante para una Raspberry Pi 5 como *gateway* de seguridad: aun con mayor capacidad que microcontroladores, el IDS debe ser sostenible y no degradar la operación del nodo.

El tercer eje del estado del arte aborda el **aprendizaje federado** (FL) como alternativa para entrenar IDS sin centralizar datos crudos, una necesidad frecuente en entornos IoT/IIoT por políticas de privacidad y costos de transferencia. Imteaj et al. sintetizan retos fundamentales del FL en dispositivos restringidos, destacando la heterogeneidad de hardware, conectividad intermitente, participación parcial y datos *non-IID* como limitantes principales [4]. En IDS federados, se han propuesto enfoques que buscan eficiencia y ligereza mediante integración *cross-layer* para reducir sobrecarga de comunicación y mantener desempeño [7]. Asimismo, se han explorado estrategias de personalización/adaptación local para mejorar el desempeño en dominios heterogéneos, donde cada nodo observa patrones de tráfico distintos [10]. En IIoT, también se reportan diseños que emplean redes más profundas (p. ej., enfoques con redes residuales) para capturar patrones complejos dentro de un esquema federado [32]. En conjunto, estas contribuciones muestran que FL es prometedor, pero exige decisiones explícitas sobre particionamiento de datos, frecuencia de rondas, compresión de actualizaciones y tolerancia a conectividad eventual.

Un cuarto eje se relaciona con la **seguridad y confidencialidad** en el ciclo de vida de datos y modelos. Aunque FL disminuye la necesidad de centralizar datos crudos, no elimina riesgos sobre artefactos intercambiados o almacenados (actualizaciones de modelo, pesos, registros derivados o configuraciones). En este escenario, la criptografía ligera adquiere relevancia como mecanismo para proteger información *en tránsito* y *en reposo* bajo restricciones de cómputo. NIST estandarizó primitivas basadas en Ascon para cifrado autenticado y funciones *hash* orientadas a dispositivos restringidos [9]. A nivel de síntesis, revisiones recientes discuten criterios de selección e implementación de criptografía ligera en IoT, resaltando los compromisos entre seguridad, rendimiento y complejidad de implementación [33]. Esto soporta la inclusión de cifrado ligero como requisito de viabilidad (no accesorio) cuando el IDS se despliega en el borde y coordina aprendizaje/actualización distribuida.

El quinto eje del estado del arte corresponde al uso de **NLP y Transformers** para análisis de logs y telemetría. LogBERT formaliza el uso de modelos tipo BERT para representar secuencias de logs y detectar anomalías, mostrando que los registros semiestructurados pueden tratarse como "lenguaje" para capturar contexto temporal [6]. En una línea posterior, LTAnomaly propone Transformers especializados para robustecer la detección frente a variabilidad y ruido en registros [8]. En escenarios distribuidos, se han planteado Transformers federados e interpretables para aprendizaje de patrones de logs sin centralizar datos, conectando directamente con la combinación FL+NLP propuesta [34]. Adicionalmente, se han explorado modelos de lenguaje como clasificadores sobre logs derivados de red (p. ej., Zeek), resaltando su potencial para extraer patrones semánticos o secuenciales a partir de eventos de red estructurados [5].

A partir de esta revisión, se identifica una brecha de investigación práctica: aunque existen

aportes sólidos por separado en (i) TinyML/edge IDS, (ii) FL para IDS, (iii) criptografía ligera y (iv) NLP para logs, es menos frecuente encontrar una **integración completa y evaluada end-to-end** en un nodo de borde realista (como Raspberry Pi) que utilice capturas PCAP (Wireshark) para derivar flujos/logs, ejecute inferencia eficiente, actualice modelos de forma federada y asegure artefactos con cifrado ligero, reportando simultáneamente métricas de precisión y métricas operativas (latencia, RAM/CPU y, cuando aplique, energía). Esta tesis se posiciona para cubrir dicha brecha, proponiendo una arquitectura experimental integral que combine aprendizaje eficiente en el borde con entrenamiento distribuido y analítica basada en NLP para mejorar tanto la detección como la interpretabilidad de alertas.

Table 2-1.: Resumen del Estado del Arte en IDS para IoT/IIoT con Edge/TinyML, FL, criptografía ligera y NLP.

Referencia	**Enfoque**	**Datos / Escenario**	**Aporte clave**
[25]	Dataset NIDS	Intrusión en red (benchmark)	Baseline clásico para comparación de IDS
[26]	Dataset IoT	Tráfico IoT con botnet/ataques	Escenarios orientados a botnets en IoT
[27, 28]	Dataset multimodal	Telemetría + logs + tráfico	Soporta evaluación multimodal IoT/IIoT
[30]	Dataset (central/FL)	IoT/IIoT para centralizado y federado	Diseñado explícitamente para FL y realismo
[29]	Dataset PCAP	Escenarios IoT benigno/malware (PCAP)	Facilita pipelines desde Wireshark/PCAP
[31]	Dataset benchmark	IoT a gran escala	Diversidad de ataques recientes y volumen alto
[3]	TinyML Survey	Revisión en IoT	Estrategias de eficiencia (compresión, cuantización)
[2]	Edge IDS	Evaluación *on-device*	Energía/latencia como métricas críticas en IDS IoT
[4]	FL Survey	IoT restringido	Retos: *non-IID*, conectividad, heterogeneidad

Table 2-1 – continuación de la página anterior

Referencia	Enfoque	Datos / Escenario	Aporte clave
[7]	FL + IDS	IoT (ligero)	IDS federado eficiente (*cross-layer*)
[10]	FL + IDS	IoT (personalización)	Adaptación local del modelo en entornos heterogéneos
[32]	FL + IDS	IIoT (modelos profundos)	ResNets federados para patrones complejos
[9]	Cripto ligera	Estándar NIST	Ascon para cifrado autenticado en restringidos
[33]	Cripto ligera Survey	Revisión IoT	Criterios de selección e implementación eficiente
[6]	NLP en logs	Secuencias de logs	BERT para detección de anomalías en registros
[8]	NLP en logs	Transformer especializado	Mejoras ante variabilidad y ruido en logs
[34]	NLP + FL	Logs distribuidos	Transformer federado e interpretable para anomalías
[5]	NLP en red	Zeek logs	Evaluación de LLMs como clasificadores en logs de red

3. Metodología

4. Resultados

5. Conclusiones y Trabajos Futuros

Bibliografía

[1] National Institute of Standards and Technology (NIST), "The NIST Cybersecurity Framework (CSF) 2.0," NIST, 2024, accessed: 2026-02-07. [Online]. Available: https://www.nist.gov/cyberframework

[2] B. Tekin *et al.*, "Energy consumption of on-device machine learning models for iot intrusion detection," *Internet of Things*, p. 100670, 2023.

[3] L. Dutta and S. Bharali, "Tinyml meets iot: A comprehensive survey," *Internet of Things*, vol. 16, p. 100461, 2021.

[4] A. Imteaj, U. Thakker, S. Wang, J. Li, and M. H. Amini, "A survey on federated learning for resource-constrained iot devices," *IEEE Internet of Things Journal*, vol. 9, no. 1, pp. 1–24, 2022.

[5] S. Yadav *et al.*, "Evaluation of llm classifiers on zeek logs," *arXiv preprint*, 2023. [Online]. Available: https://arxiv.org/abs/2311.07042

[6] H. Guo, H. Yuan *et al.*, "Logbert: Log anomaly detection via bert," *arXiv preprint*, 2021. [Online]. Available: https://arxiv.org/abs/2103.04475

[7] S. Hajj, J. Azar, J. Bou Abdo, J. Demerjian, C. Guyeux, A. Makhoul, and D. Ginhac, "Cross-layer federated learning for lightweight iot intrusion detection systems," *Sensors*, vol. 23, no. 16, p. 7038, 2023.

[8] Y. Han *et al.*, "Ltanomaly: Log transformer-based anomaly detection," *arXiv preprint*, 2023. [Online]. Available: https://arxiv.org/abs/2309.05613

[9] National Institute of Standards and Technology (NIST), "Ascon-Based Lightweight Cryptography Standardization for Constrained Devices," NIST Special Publication 800-232, Aug. 2025, accessed: 2026-02-07. [Online]. Available: https://csrc.nist.gov/pubs/sp/800/232/final

[10] S. Roy, J. Li, and Y. Bai, "Federated learning-based intrusion detection system for iot environments with locally adapted model," in *2023 IEEE 10th International Conference on Cyber Security and Cloud Computing (CSCloud) / 2023 IEEE 9th International Conference on Edge Computing and Scalable Cloud (EdgeCom)*, 2023, pp. 203–209.

[11] National Institute of Standards and Technology, "The NIST Cybersecurity Framework (CSF) 2.0," NIST, Tech. Rep. NIST CSWP 29, Feb. 2024. [Online]. Available: https://nvlpubs.nist.gov/nistpubs/CSWP/NIST.CSWP.29.pdf

[12] C. Amuthadevi, S. P. R. Kavin, A. Shrestha, N. R. S. Yamini, and D. K. Sharma, "Tinyml-based intrusion detection system for sustainable iot security: A novel approach," *Results in Engineering*, 2025.

[13] Z. Alwaisi, E. Harjula, T. Kumar, and S. Soderi, "Securing constrained iot systems: A lightweight machine learning approach for anomaly detection and prevention," *Internet of Things*, 2024.

[14] N. Tekin, A. Acar, A. Aris, A. S. Uluagac, and V. C. Gungor, "Energy consumption of on-device machine learning models for iot intrusion detection," *Internet of Things*, vol. 21, p. 100670, 2023.

[15] UNSW Canberra at ADFA, "The TON_IoT Datasets," 2026, accessed: Feb. 4, 2026. [Online]. Available: https://research.unsw.edu.au/projects/toniot-datasets

[16] E. C. P. Neto *et al.*, "Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment," *Sensors*, vol. 23, no. 13, p. 5941, 2023.

[17] L. Mehavilla, M. Rodríguez, J. García, and Á. Alesanco, "Evaluating large language models effectiveness for flow-based intrusion detection: a comparative study with ml and dl baselines," *Artificial Intelligence Review*, 2025.

[18] Raspberry Pi Ltd, "Raspberry Pi 5 Product Brief," Feb. 2026. [Online]. Available: https://pip.raspberrypi.com/documents/RP-008348-DS-3-raspberry-pi-5-product-brief.pdf

[19] H. Alsghaier and T. Zhao, "Software engineering aspects of federated learning libraries: A comparative survey," *Software*, vol. 4, no. 4, p. 28, 2025.

[20] N. Albanbay, F. B. Ajaei, and A. Shami, "Federated learning-based intrusion detection in iot networks: Performance evaluation and data scaling study," *Journal of Sensor and Actuator Networks*, vol. 14, no. 4, p. 78, 2025.

[21] National Institute of Standards and Technology, "Ascon-Based Lightweight Cryptography Standards for Constrained Devices: Authenticated Encryption, Hash, and Extendable Output Functions," NIST, Tech. Rep. NIST SP 800-232, Aug. 2025. [Online]. Available: https://nvlpubs.nist.gov/nistpubs/SpecialPublications/NIST.SP.800-232.pdf

[22] B. Guşiţa, R. Doroftei, and M. F. Ionescu, "Lightweight cryptography for iot devices: a survey," *International Journal of Information Security*, vol. 24, pp. 305–329, 2025.

[23] G. D. L. T. Parra, A. Kilany, N. Aris, and S. Kiyomoto, "Interpretable federated transformer log learning for anomaly detection," in *Proceedings of the NDSS Symposium*, 2022.

[24] H. Guo, S. Yuan, and X. Wu, "Logbert: Log anomaly detection via bert," arXiv:2103.04475, 2021. [Online]. Available: https://arxiv.org/abs/2103.04475

[25] University of New South Wales (UNSW), "UNSW-NB15 Dataset," 2026, dataset download page. Accessed: 2026-02-07. [Online]. Available: https://research.unsw.edu.au/projects/unsw-nb15-dataset

[26] ——, "Bot-IoT Dataset," 2026, dataset download page. Accessed: 2026-02-07. [Online]. Available: https://research.unsw.edu.au/projects/bot-iot-dataset

[27] ——, "TON_IoT Datasets," 2026, dataset download page. Accessed: 2026-02-07. [Online]. Available: https://research.unsw.edu.au/projects/toniot-datasets

[28] N. Moustafa, C. Schmitt *et al.*, "Ton_iot: The telemetry dataset for internet of things and industrial internet of things," *IEEE Access*, 2020.

[29] Stratosphere IPS, Czech Technical University in Prague, "IoT-23: A labeled dataset of IoT network traffic," 2026, dataset page. Accessed: 2026-02-07. [Online]. Available: https://www.stratosphereips.org/datasets-iot23

[30] M. A. Ferrag, L. Maglaras *et al.*, "Edge-iiotset: A new comprehensive realistic cyber security dataset of iot and iiot applications for centralized and federated learning," *IEEE Access*, 2022.

[31] E. C. P. Neto, J. P. Papa *et al.*, "Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment," *Sensors*, vol. 23, no. 13, p. 5941, 2023.

[32] N. Chaurasia, M. Ram, P. Verma, N. Mehta, and N. Bharot, "A federated learning approach to network intrusion detection using residual networks in industrial iot networks," *The Journal of Supercomputing*, vol. 80, pp. 18 325–18 346, 2024.

[33] F. Gusita, S. Rahimi *et al.*, "Lightweight cryptography for internet of things devices: a survey," *Jurnal Ilmiah Teknik Elektro Komputer dan Informatika (JITEKI)*, vol. 11, no. 2, pp. 153–170, 2025.

[34] X. Ma *et al.*, "Interpretable federated transformer log learning for anomaly detection," in *Network and Distributed System Security Symposium (NDSS)*, 2022. [Online]. Available: https://www.ndss-symposium.org/ndss-paper/interpretable-federated-transformer-log-learning-for-anomaly-detection/

A. Anexos

A.1. Anexo A: Resultados Suplementarios